

Minería de Datos

II. Proceso de la Minería de Datos

I. C. Juan José Acosta Espinoza

ANALYTICS
AS A SERVICE

PREDICTIVE
MODELING

DATA MINING

ANALYTICS

DECISION
MAKING

4 marzo 2023

1 Proceso de la Minería de Datos

2 Preparación de los datos

Cross-Industry Standard Process for Data Mining

Proceso Estándar entre Industrias para la Minería de Datos




Fig. 1: Modelo CRISP DM.

1. Comprensión del negocio

El **científico de datos o minero de datos** comienza por identificar los objetivos y el alcance del proyecto. Trabajan conjuntamente con las partes interesadas de la empresa para identificar cierta información.

- Problemas que se deben abordar
- Restricciones o limitaciones del proyecto
- El impacto empresarial de las posibles soluciones

A continuación, utilizan esta información para definir los objetivos de la minería de datos e identificar los recursos necesarios para el descubrimiento de conocimientos.

2. Comprensión de los datos

Una vez que comprenden el problema empresarial, los científicos de datos comienzan a realizar un análisis preliminar de los datos.

Recopilan conjuntos de datos de diversos orígenes, obtienen los derechos de acceso y elaboran un informe de descripción de datos.

El informe incluye los tipos de datos, la cantidad y los requisitos de hardware y software para el procesamiento de datos. En cuanto la empresa aprueba el plan, comienzan a explorar y verificar los datos.

Manejan los datos mediante técnicas estadísticas básicas, evalúan la calidad de los datos y eligen un conjunto de datos final para la siguiente fase.

3. Preparación de los datos

Los mineros de datos dedican la mayor parte del tiempo a esta fase porque el software de minería de datos requiere datos de alta calidad. Los procesos empresariales recopilan y almacenan datos por razones distintas a la minería. Por ello, los mineros de datos deben perfeccionarlos antes de utilizarlos para el modelado. La preparación de los datos implica los siguientes procesos.

- **Limpiar los datos**

Por ejemplo, gestionar los datos que faltan, los errores de datos, los valores predeterminados y las correcciones de datos.

- **Integrar los datos**

Por ejemplo, combinar dos conjuntos de datos dispares para obtener el conjunto de datos objetivo final.

- **Dar formato a los datos**

Por ejemplo, convertir los tipos de datos o configurar los datos para la tecnología de minería específica que se utiliza.

4. Modelado de datos

Los mineros de datos introducen los datos preparados en el software de minería de datos y estudian los resultados. Para ello, pueden elegir entre múltiples técnicas y herramientas de minería de datos. Además, deben escribir pruebas para evaluar la calidad de los resultados de la minería de datos. Para modelar los datos, los científicos de datos cuentan con las siguientes opciones:

- Entrenar los modelos de **machine learning** (ML) a partir de conjuntos de datos más pequeños con resultados conocidos
- Utilizar el modelo para analizar más a fondo conjuntos de datos desconocidos
- Ajustar y volver a configurar el software de minería de datos hasta que los resultados sean satisfactorios

5. Evaluación

Una vez creados los modelos, los mineros de datos comienzan a medirlos con respecto a los objetivos empresariales originales. Comparten los resultados con los analistas de negocio y obtienen comentarios.

Es posible que el modelo responda adecuadamente a la pregunta original o que muestre patrones nuevos y desconocidos hasta el momento. Los mineros de datos pueden modificar el modelo, ajustar el objetivo empresarial o volver a revisar los datos, en función de los comentarios empresariales.

La evaluación continua, los comentarios y las modificaciones forman parte del proceso de descubrimiento de conocimientos.

6. Implementación

Durante la implementación, otras partes interesadas utilizan el modelo de trabajo para generar inteligencia empresarial. El científico de datos planifica el proceso de implementación, que incluye instruir a otros sobre las funciones del modelo, realizar un seguimiento continuo y mantener la aplicación de minería de datos.

Los analistas empresariales utilizan la aplicación para crear informes para la dirección, compartir los resultados con los clientes y mejorar los procesos empresariales.

1 Proceso de la Minería de Datos

2 Preparación de los datos

Limpieza de datos

Integración de datos

Calidad de datos

¿Por qué preprocesar los datos?

- Precisión: correcto o incorrecto, exacto o no
- Integridad: no registrado, no disponible,
- Coherencia: algunas modificadas pero otras no,
- Puntualidad: ¿actualización oportuna?
- Credibilidad: ¿Qué tan confiables son los datos correctos?
- Interpretabilidad: ¿Con qué facilidad se pueden entender los datos?

Principales tareas en el preprocesamiento de datos

- **Limpieza de datos**

Complete los valores que faltan, suavice los datos ruidosos, identifique o elimine los valores atípicos y resuelva las inconsistencias

- **Integración de datos**

Integración de múltiples bases de datos, cubos de datos o archivos

- **Reducción de datos**

Reducción de dimensionalidad

Reducción de numerosidad

Compresión de datos

- **Transformación y discretización de datos**

Normalización

Generación de jerarquía de conceptos

Limpieza de datos

Los datos en el mundo real están sucios: hay una gran cantidad de datos potencialmente incorrectos, por ejemplo, instrumento defectuoso, error humano o informático, error de transmisión

- **incompleto:** carece de valores de atributos, carece de ciertos atributos de interés o contiene solo datos agregados
ej., Ocupación="" (datos faltantes)
- **ruidoso:** que contiene ruido, errores o valores atípicos
ej., Salario="10" (un error)
- **inconsistente:** que contiene discrepancias en códigos o nombres:
 - Edad=42, Cumpleaños=07/03/2020
 - Calificaba 1, 2, 3, ahora califica A, B, C
 - discrepancia entre registros duplicados
- **Intencional** (p. ej., datos faltantes encubiertos)
¿El 1 de enero es el cumpleaños de todos?

Datos incompletos(faltantes)

- Los datos no siempre están disponibles
Por ejemplo, muchas tuplas no tienen valor registrado para varios atributos, como los ingresos de los clientes en los datos de ventas.
- Los datos faltantes pueden deberse a:
 - mal funcionamiento del equipo
 - inconsistencia con otros datos registrados y por lo tanto borrados
 - datos no ingresados debido a un malentendido
 - ciertos datos pueden no ser considerados importantes en el momento de la entrada
 - no registrar historial o cambios de los datos
- Es posible que sea necesario inferir los datos faltantes

¿Cómo manejar los datos faltantes?

- Ignorar la tupla: generalmente se realiza cuando falta la etiqueta de clase (al realizar la clasificación)
no es efectivo cuando el % de valores faltantes por atributo varía considerablemente
- Complete el valor faltante manualmente: ¿tedioso + inviable?
- Rellénalo automáticamente con:
 - una constante global: p.e. "desconocido", ¿una nueva clase?
 - la **media aritmética** del atributo
 - la media del atributo para todas las muestras pertenecientes a la misma clase: **más inteligente**
 - el valor más probable: basado en inferencias como la fórmula bayesiana o el árbol de decisión

Datos con ruido

Ruido: error aleatorio o varianza en una variable medida

Los valores de atributo incorrectos pueden deberse a:

- instrumentos de recopilación de datos defectuosos
- problemas de entrada de datos
- problemas de transmisión de datos
- limitación tecnológica
- inconsistencia en la convención de nomenclatura
- registros duplicados

¿Cómo manejar datos ruidosos?

- **Binning** (Agrupamiento discreto de datos)
Primero ordene los datos y particione en contenedores bin (de igual frecuencia)
entonces uno puede suavizar por bin means, suavizar por bin median, suavizar por límites de bin, etc.
- **Regresión**
suave ajustando los datos en funciones de regresión
- Agrupación (**Clustering**)
detectar y eliminar valores atípicos
- Inspección combinada por computadora y humana
detectar valores sospechosos y verificar por humanos (por ejemplo, tratar con posibles valores atípicos)

Limpieza de datos como proceso

Detección de discrepancia en datos

- Use metadatos
(dominio, rango, dependencia, distribución)
- Compruebe la sobrecarga de campo
- Compruebe las reglas de unicidad, valor consecutivo y valores nulos
- Use herramientas comerciales:
 - Depuración de datos: use conocimiento de dominio simple (código postal, corrector ortográfico) para detectar errores y hacer correcciones.
 - Auditoría de datos: use el análisis de datos para descubrir reglas y relaciones que detecten problemas (correlación y agrupación para encontrar valores atípicos)

Migración e integración de datos

- Herramientas de migración de datos:
permiten especificar transformaciones
- **Herramientas ETL** (Extracción/Transformación/Carga):
permiten a los usuarios especificar transformaciones a través
de una interfaz gráfica de usuario

Integración de los dos procesos.

Iterativo e interactivo (p. ej., **Potters Wheels**)

Integración de datos

- Combinar datos de múltiples fuentes en un almacenamiento coherente (bases de datos, sitios web, archivos Excel, CSV, almacenes de datos, etc.)
- Integración de esquemas (relacional, objetos, JSON, grafos, cubos de datos)
- Problemas para identificar entidades o atributos en múltiples fuentes de datos:
Juan Acosta = José Acosta
Posibles razones: diferentes representaciones, diferentes escalas, por ejemplo, unidades métricas vs unidades británicas

Manejo de la redundancia en la integración de datos

- Los datos redundantes ocurren a menudo cuando se integran múltiples bases de datos.
- Datos derivables: un atributo puede ser un atributo "derivado" en otra tabla, por ejemplo, ingresos anuales
- Los atributos redundantes pueden detectarse mediante **análisis de correlación y covarianza**