

Minería de Datos

I. Introducción

I. C. Juan José Acosta Espinoza

ANALYTICS
AS A SERVICE

PREDICTIVE
MODELING

DATA MINING

ANALYTICS

DECISION
MAKING

25 febrero 2023

- ① 1. Introducción
- ② Aplicaciones
- ③ Tipos de Análisis
- ④ Tipos de aprendizaje

¿Qué es la minería de datos?

La **minería de datos** es el proceso de hallar anomalías, patrones y correlaciones en grandes conjuntos de datos para predecir resultados. Empleando una amplia variedad de técnicas, puede utilizar esta información para incrementar sus ingresos, recortar costos, mejorar sus relaciones con clientes, reducir riesgos y más.

Pero su base comprende tres disciplinas científicas entrelazadas:

- Estadística (el estudio numérico de relaciones de datos)
- Machine learning (algoritmos que pueden aprender de datos para hacer predicciones).
- Inteligencia artificial (inteligencia similar a la humana exhibida por software y/o máquinas)



Fig. 1: Relación de la Minería de Datos con otras ciencias

- El término KDD (iniciales de **Knowledge Discovery in Databases**), acuñado en 1989 se refiere a todo el proceso de extracción de conocimiento a partir de una base de datos y marca un cambio de paradigma en el que lo importante es el conocimiento útil que seamos capaces de descubrir a partir de los datos.
- La Minería de Datos es un paso particular en el proceso KDD consistiendo en la aplicación de algoritmos específicos para extraer patrones (modelos) de los datos. Otros pasos en el proceso KDD, son: la preparación de los datos, la selección y limpieza de los mismos, la incorporación de conocimiento previo, y la propia interpretación de los resultados de minería.
- Las tareas propias de la fase de minería de datos pueden ser **descriptivas**, (i.e. descubrir patrones interesantes o relaciones describiendo los datos), o **predictivas** (i.e. clasificar nuevos datos basándose en los anteriormente disponibles). En otras palabras, es un campo interdisciplinar con el objetivo general de predecir las salidas y revelar relaciones en los datos.

- Otro concepto relacionado con el KDD es el de **Data warehousing**, que se refiere a las tendencias actuales en la recolección y limpieza de datos transaccionales para dejarlos disponible para el análisis y la toma de decisiones.
- El concepto de Minería de Datos también se solapa con los conceptos de aprendizaje automático y de estadística. En general, la **estadística** es la primera ciencia que históricamente extrae información de los datos básicamente mediante metodologías procedentes de las matemáticas.
- Cuando se empezó a usar los ordenadores como apoyo para esta tarea surgió el concepto de **Machine Learning**, traducido como Aprendizaje Automático.
- Posteriormente con el incremento del tamaño y con la estructuración de los datos es cuando se empieza a hablar de Minería de Datos y más recientemente **Big Data**.

- ① 1. Introducción
- ② Aplicaciones
- ③ Tipos de Análisis
- ④ Tipos de aprendizaje

¿En dónde se utiliza?

Finanzas y Seguros

Detección de fraude

Gestión riesgo

Marketing

Mejora campañas

Sistemas de recomendación

RRHH

Optimización
procesos selección

CRM

Segmentación de
clientes

Salud

Análisis de
supervivencia

Industria

Mantenimiento
predictivo

- **Comunicaciones**

En un mercado sobrecargado donde la competencia es cerrada, las respuestas se encuentran a menudo en los datos de sus consumidores. Las compañías de multimedia y telecomunicaciones pueden utilizar modelos analíticos para entender montañas de datos de clientes, ayudándoles así a predecir el comportamiento de sus clientes y ofrecer campañas altamente dirigidas y relevantes.

- **Manufactura**

La alineación de planes de suministro con pronósticos de demanda es esencial, como lo es también la detección temprana de problemas, garantía de calidad e inversión en equidad de marca. Los fabricantes pueden predecir el desgaste de activos de producción y anticipar su mantenimiento, lo cual puede maximizar el tiempo en operación y mantener la línea de producción acorde a lo programado.

- **Bancos**

Los algoritmos automatizados ayudan a los bancos a entender a su base de clientes y también los miles de millones de transacciones del sistema financiero. La minería de datos ayuda a las compañías de servicios financieros a tener una mejor vista de los riesgos del mercado, a detectar el fraude en menos tiempo, a gestionar las obligaciones de cumplimiento de las regulaciones y a obtener retornos óptimos de sus inversiones en marketing.

- **Seguros**

Con conocimientos analíticos, las compañías de seguros pueden resolver problemas complejos concernientes a fraude, cumplimiento, gestión de riesgo y separación de clientes. Las compañías han utilizado técnicas de minería de datos para asignar precios a productos con mayor eficacia en líneas de negocios y hallar nuevas formas de ofrecer productos competitivos a su base de clientes existente.

- **Educación**

Con vistas unificadas basadas en datos del progreso de los estudiantes, los educadores pueden predecir el desempeño de sus alumnos antes de que pongan un pie en el salón de clases y desarrollar estrategias de intervención para mantenerlos en curso. La minería de datos ayuda a los educadores a acceder a datos de los estudiantes, a predecir niveles de logro y a detectar estudiantes o grupos de estudiantes que necesitan atención extra.

- **Retail**

Grandes bases de datos de clientes contienen insights ocultos que le pueden ayudar a mejorar las relaciones con clientes, optimizar campañas de marketing y pronosticar ventas. A través de modelos de datos más precisos, las compañías detallistas pueden ofrecer campañas más enfocadas y encontrar la oferta que tenga el mayor impacto en el cliente.

- ① 1. Introducción
- ② Aplicaciones
- ③ Tipos de Análisis**
- ④ Tipos de aprendizaje

Tipos de Análisis

El objetivo del Análisis de Datos (Data Analytics), en conjuntos de datos tanto grandes como pequeños, es obtener información que resulte de utilidad para la una toma de decisiones más inteligente y obtenga los resultados empresariales deseados. Claramente, la forma de obtener los datos, así como las herramientas de análisis pueden variar, la técnica para realizar hallazgos varía en muy poco. Existen tres tipos de análisis de datos:

- Descriptivo (inteligencia empresarial y minería de datos)
- Predictivo (pronóstico)
- Prescriptivo (optimización y simulación)

Análisis Descriptivo

La analítica descriptiva examina los datos y analiza los acontecimientos pasados para saber cómo abordar el futuro. La analítica descriptiva examina el rendimiento pasado y entiende ese rendimiento al extraer datos históricos para buscar las razones detrás del éxito o el fracaso del pasado. Casi todos los informes de gestión, tales como ventas, marketing, operaciones y finanzas, utilizan este tipo de análisis post-mortem.

Los modelos descriptivos cuantifican las relaciones en los datos de una manera que se utiliza a menudo para clasificar a clientes o prospectos en grupos. A diferencia de los modelos predictivos que se centran en predecir un solo comportamiento del cliente (como el riesgo de crédito), los modelos descriptivos identifican muchas relaciones diferentes entre clientes o productos.

Los modelos descriptivos pueden usarse, por ejemplo, para clasificar a los clientes según sus preferencias de producto y su etapa de vida. Por ejemplo, la analítica descriptiva examina los datos históricos de uso de la electricidad para ayudar a planificar las necesidades de energía y permitir a las compañías eléctricas establecer precios óptimos.

Detección de anomalías	Identificación de valores atípicos multidimensionales.
Aprendizaje de reglas de asociación	Detección de relaciones entre registros.
Análisis de componentes principales	Detección de relaciones entre variables.
Agrupación por afinidad	Agrupación de personas con intereses comunes o metas similares (por ejemplo, personas que compran X a menudo compran Y y posiblemente Z).

Table 1: Algoritmos descriptivos

Análisis Predictivo

El análisis predictivo utiliza datos para determinar el resultado futuro probable de un evento o la probabilidad de que se produzca una situación.

El análisis predictivo abarca una variedad de técnicas estadísticas de modelado, aprendizaje de máquina (Machine Learning), minería de datos y teoría de juegos que analizan los hechos actuales e históricos para hacer predicciones sobre eventos futuros.

En los negocios, los modelos predictivos explotan patrones encontrados en datos históricos y transaccionales para identificar riesgos y oportunidades. Los modelos captan las relaciones entre muchos factores para permitir la evaluación del riesgo o potencial asociado con un conjunto particular de condiciones, guiando la toma de decisiones para las transacciones candidatas.

Un ejemplo de uso de análisis predictivo es la optimización de los sistemas de gestión de relaciones con los clientes. Pueden ayudar a permitir que una organización analice todos los datos de los clientes, exponiendo así los patrones que predicen el comportamiento del cliente. (Google, Netflix)

Otro ejemplo es para una organización que ofrece múltiples productos, la analítica predictiva puede ayudar a analizar el gasto, el uso y otros comportamientos de los clientes, lo que conduce a ventas cruzadas eficaces o vende productos adicionales a los clientes actuales. Esto conduce directamente a una mayor rentabilidad por cliente y a relaciones más fuertes con los clientes. (Walmart, Mercado Libre)

Análisis Prescriptivo

El análisis prescriptivo, englobado en el área de la analítica empresarial, consiste en recopilar datos, recomendar acciones y prever qué impacto tendrán para facilitar la toma de decisiones, identificando la mejor solución de entre todas las posibles.

El análisis prescriptivo se basa en la investigación de operaciones, en análisis predictivos (machine learning) y técnicas estadísticas para cuantificar el efecto de las decisiones futuras (simulación y optimización): a partir de datos actuales e históricos, permite estimar qué es probable que suceda y recomendar, entre diversas alternativas, un plan de acción óptimo. La analítica prescriptiva se ampara en sistemas de gestión y algoritmos que automatizan la toma de decisiones y mejoran la eficiencia operativa de las compañías.

En conclusión

El análisis descriptivo consiste en recopilar y analizar datos históricos para responder qué ha pasado y cuál es el estado actual del negocio. Por su parte, el análisis predictivo combina datos históricos, reglas y algoritmos avanzados para anticiparse o estimar qué podría acaecer, con el propósito de hacer pronósticos y adelantarse a situaciones futuras.

El análisis prescriptivo se considera la tercera fase de la analítica empresarial porque recopila información de las dos analíticas comúnmente empleadas por la mayoría de empresas: la descriptiva y la predictiva.

- ① 1. Introducción
- ② Aplicaciones
- ③ Tipos de Análisis
- ④ Tipos de aprendizaje

Tipos de aprendizaje

- Los algoritmos denominados de "**Machine Learning**", se dividen en 3 grandes grupos: supervisados, no supervisados y por refuerzo.
- El aprendizaje **supervisado** se realiza con información "conocida"/"etiquetada" de tal manera que se utiliza para modelos predictivos.
- El aprendizaje **no supervisado** no requiere conocer la fuente de la información por lo que el objetivo es realizar modelos descriptivos.
- El aprendizaje **por refuerzo** es aquel dónde se busca la optimización de una decisión basado en recompensas. Aunque los algoritmos pueden ser supervisados o no supervisados, se diferencia principalmente por la incapacidad computacional de estos para resolverlo. Los modelos para decidir la mejor jugada en una partida de ajedrez son un ejemplo clásico.

- Al proceso de entrenamiento de un modelo predictivo se le conoce como aprendizaje supervisado, lo que no implica una intervención o participación humana, sino a la definición de los valores introducidos para el pronóstico. Dado un conjunto de datos, el algoritmo de aprendizaje optimiza o crea una "función" (modelo) cuya "valuación" en los valores de entrada resultan en el objetivo a pronosticar.
- Los modelos predictivos pueden predecir categorías (**Modelos de clasificación**) o valores (**Modelos de regresión**), aunque estos modelos no están peleados pues una variable es fácilmente convertible en categórica y alguna categórica se puede convertir en numérica (binaria por categoría).

- Los modelos descriptivos son utilizados para agrupar o resumir los datos sin tener un objetivo final definido, razón por la cuál se le denomina aprendizaje no supervisado.
- Los modelos descriptivos que agrupan los datos por sus características se llaman "**Modelos de Agrupamiento (Clustering)**" y son usados para segmentar o agrupar la información, por ejemplo, la agrupación de personas por sus características médicas, por cualidades conductuales, comportamiento de compra, entre otros. Los modelos de clustering, aunque clasifiquen correctamente en términos matemáticos, requieren de un humano para su interpretación.

- Los modelos descriptivos que forman nuevas variables a partir de la información inicial se llaman **"Modelos de reducción de dimensionalidad"**. El termino "reducción" hace referencia a que los algoritmos se enfocan en la síntesis de la información pudiendo ser el resultado final útil por si mismo o la antesala a la aplicación de otro modelo.

“Aunque existen diversos modelos para cada problema, el algoritmo elegido dependerá fuertemente de la necesidad y capacidad propia del mismo. Por ejemplo, tamaño de la muestra, tipo de aprendizaje, tiempo de desarrollo o capacidad computacional suelen ser cruciales al momento de elegir”.