



Minería de Datos

I. Preprocesamiento de los datos

Tarea 1

Datos faltantes

Con el repositorio cervical-cancer_csv que esta disponible en el siguiente enlace:

[Cervical cancer - Dataset - DataHub - Frictionless Data](#)

Realice lo siguiente en un Notebook de Jupyter:

1. Cargue los datos en Python usando Pandas y muestre los primeros 10 registros
2. Como todas las columnas son numéricas para poder trabajar una columna categórica ejecute la siguiente línea:

```
df["STDs (number)"]=df["STDs (number)"].replace([0,1,2,3,4],["muy bajo","bajo","medio","alto","muy alto"])
```

Esta instrucción reemplaza todos los valores de: 0,1,2,3,4 en la columna "STDs (number)" por las categorías: "muy bajo","bajo","medio", "alto","muy alto" respectivamente.

Puede consultar más ejemplos de replace en [pandas-replace-values-in-column](#)

3. Identifique que porcentaje de valores faltantes tiene cada columna
4. Elimine todos los registros que tienen NaN en la columna 'Smokes'
5. Verifique si todavía faltan valores para el resto de las columnas.
6. Elimine todas las columnas que no tienen al menos el 70% de valores no nulos
7. Verifique el tipo de las columnas
8. Reemplace los valores faltantes de las columnas numéricas por la **media aritmética**.
9. Verifique si todavía faltan valores para el resto de las columnas.
10. Reemplace los valores faltantes de la columna categórica "STDs (number)" por la **moda** de esa columna
11. Compruebe que ya no queda ningún valor NaN
12. Vuelva a cargar los datos y realice una **interpolación** para reemplazar los datos faltantes de las columnas numéricas.