



Minería de Datos

I. Preprocesamiento de los datos

Tarea 2

Datos anómalos/ atípicos/ outliers

Con el repositorio "hepatitis.csv" que revisamos en el tema de ***Datos Faltantes*** realice lo siguiente en un Notebook de Jupyter. De preferencia utilice el mismo notebook o exporte el resultado anterior a un archivo CSV.

Para exportar el archivo a CSV:

```
df.to_csv("hepatitis_sinNAN.csv",index=False)
```

O si usará el mismo notebook agregue una celda de texto (*Markdown*)

```
<h1> Datos anómalos/ atípicos/ outliers </h1>
```

1. Cargue los datos en Python usando Pandas y muestre los primeros 10 registros
2. Realice un histograma de la columna **albumin**.
3. Realice el diagrama de cajas para analizar la distribución de los datos.
***NOTA:** la columna no debe tener datos faltantes, realice la sustitución de *NaN* por la **media** o por **interpolación**.
4. Obtenga los valores de los cuartiles 1 y 3 y del rango intercuartil IQR.
5. Obtenga los valores de los bigotes inferior y superior.
6. Obtenga la ubicación de los outliers.
7. Consulte el valor de los outliers.
8. Con la condición que uso en el paso 6 elimine los outliers del dataframe:

```
df.drop(df.loc[(df["albumin"]<BI) | (df["albumin"]>BS)].index, inplace=True)
```

Explicación:

```
df.loc[(df["albumin"]<BI) | (df["albumin"]>BS)]
```

extrae del dataframe aquellos registros que cumplen la condición entre corchetes (En este caso los outliers)

```
.index
```

Obtiene los índices de los registros extraídos

```
df.drop
```

Genera una copia del dataframe eliminando los registros con los índices indicados

```
Inplace=True
```

En lugar de realizar una copia hace la eliminación en el conjunto original.



Puede consultar más información del uso de drop en:

<https://sparkbyexamples.com/pandas/pandas-drop-rows-from-dataframe/>

9. Vuelva a realizar el histograma y el diagrama de cajas para ver la actual distribución de datos.
10. Repita el procedimiento con la columna **sgot**.

Lo ideal es que se realice la eliminación de outliers con las 5 columnas numéricas y exporte el resultado a CSV para la siguiente etapa de preprocesamiento.