



Minería de Datos

IV. Clustering analysis

Tarea 8

Algoritmo K-means: clasificador de vinos

Realice lo siguiente en un Notebook de Jupyter.

1. Cargue el dataset de vinos con el siguiente código de Python:
`import matplotlib.pyplot as plt`
`from sklearn import datasets`

```
wine=datasets.load_wine()  
wine.keys()
```

También puede descargarlo del siguiente enlace:

[Index of /ml/machine-learning-databases/wine \(uci.edu\)](https://ml.machine-learning-databases/wine.uci.edu)

***NOTA:** es importante que cargue los datos como un arreglo multidimensional y no como un dataframe (*as dataframe*) porque queremos hacer también un análisis con varias métricas y el algoritmo kmeans no es compatible con dataframes.

2. Revise la descripción del dataset con el siguiente comando:
`print(wine['DESCR'])`
3. Muestre los registros de las características del dataset (`wine['data']`) y de las categorías de vino (`wine['target']`).
`wine['data']`
4. Para la etapa de preprocesamiento de la tubería (pipeline) aplique la normalización de MinMaxScaler y un análisis de componentes principales (PCA) para dos componentes.
5. Configure el algoritmo de agrupamiento K-means del pipeline con los siguientes parámetros:
`n_clusters=3,`
`init="k-means++",`
`n_init=50,`
`max_iter=5000,`
`random_state=42,`
6. Entrene el modelo con los datos del dataset (`wine['data']`)
7. Consulte el resultado del agrupamiento de K-means



8. Realice las gráficas del agrupamiento real (wine['target']) y del agrupamiento con K-means para analizar qué tan acertada fue la agrupación.

- Data es wine['data']
- True_labels es wine['target']
- label_encoder.classes_ es labels=(1,2,3)

Por lo que las coordenadas x,y son:

```
x = pipe["preprocessor"].transform(wine['data'])[wine['target'] == i, 0],
y = pipe["preprocessor"].transform(wine['data'])[wine['target'] == i, 1],
```

9. Genere la matriz de confusión para saber que tanto se equivocó el algoritmo

10. Realice el análisis de **ARI** para determinar cuántos componentes principales nos conviene tomar para este problema usando el rango 2-13.

***NOTA:** solo grafique ARI, y no silueta para que se visualice mejor el resultado.

11. Con el resultado anterior vuelva a crear y entrenar el modelo. Recuerde que por ser una tubería solo tiene que ejecutar 2 líneas.

```
pipe["preprocessor"]["pca"].n_components = ¿?
pipe.fit(wine['data'])
```

12. Grafique la nueva agrupación y genere la matriz de confusión.

13. Usando las funciones purity_score y pyPurity haga un análisis de agrupamiento k-means con las siguientes métricas:

```
distance_measures = {'Euclidiana': 0, 'Euclidiana cuadrada': 1, 'Manhattan': 2,
'Chebyshev': 3, 'Canberra': 5, 'Chi-square': 6}
```

los datos de entrada son:

```
X=pipe["preprocessor"].transform(wine['data'])
```

Por lo que solo hay que ejecutar el ciclo for:

```
for measure, value in distance_measures.items():
    print(f"Purity score con distancia {measure}: {round(pyPurity(value)*100, 2)}%")
```