



Minería de Datos

V. Análisis de regresión lineal múltiple

Tarea 10

OLS: Predicción del precio de autos

Con el repositorio CarPrice_Assignment.csv que está disponible en el siguiente enlace:

<https://www.kaggle.com/datasets/hellbuoy/car-price-prediction>

Realice lo siguiente en un Notebook de Jupyter:

1. Cargue los datos en Python usando Pandas y muestre los primeros 10 registros
2. Muestre las dimensiones del dataframe (# renglones, #columnas)
3. Las columnas doornumber y cylindernumber tienen su valor con letra en inglés. Convierta su valor a numérico con el siguiente código:

```
numbers=['zero','one','two','three','four','five','six','seven','eight']
i=0
while i<9:
    df["doornumber"].replace(numbers[i],i,inplace=True)
    df["cylindernumber"].replace(numbers[i],i,inplace=True)
    i=i+1
df["cylindernumber"].replace("twelve",12,inplace=True)
df[["doornumber","cylindernumber"]].head(5)
```

4. Muestre las estadísticas (media, desv est, cuartiles, max) y el número de valores faltantes del dataframe.
5. Muestre todas las características (columnas) que posee el dataframe indicando su tipo.
6. Verifique que no hay renglones duplicados

```
df.duplicated().sum()
```

7. Realice el histograma y el diagrama de bigotes del precio.
8. Como podrá observar la marca está incluida en el nombre del auto, extráigala con el siguiente código

```
Company_Name = df["CarName"].apply(lambda x: x.split(" ")[0])
df.insert(2,"CompanyName",Company_Name)

# Now we can drop the CarName Feature.
df.drop(columns=["CarName"],inplace=True)
df.head()
```

9. Verifique los valores únicos de la marca
- ```
df["CompanyName"].unique()
```



10. Hay algunas marcas con errores por ejemplo maxda y mazda o vw y volkswagen. Ejecute el siguiente código para solucionarlo:

```
def replace (a, b):
 df["CompanyName"].replace(a, b, inplace=True)

replace('maxda', 'mazda')
replace('porcshce', 'porsche')
replace('toyouta', 'toyota')
replace('vokswagen', 'volkswagen')
replace('vw', 'volkswagen')
```

11. A partir de la marca y del precio promedio de cada marca agregue una columna que indique la gama del automóvil (baja, media, alta) con el siguiente código:

```
z = round(df.groupby(["CompanyName"])["price"].agg(["mean"]),2).T
z
```


En la salida anterior, obtenemos el precio promedio de cada compañía de automóviles individual

- i) Primero se agrupa la información del dataframe por marca (CompanyName)
- ii) Se trabaja con la columna Price
- iii) agg es el equivalente en Python al aggregate de MongoDB.  
A la salida anterior (Price agrupado por marca) le calcula el promedio (mean)
- iv) El resultado se redondea a 2 decimales round(...,2)
- v) Se obtiene la transpuesta .T para que el resultado quede como renglón (opcional)

Ahora tenemos que agregar estos valores promedio en una nueva columna en nuestro conjunto de datos.

```
df = df.merge(z.T, how="left", on="CompanyName")
```

merge es el equivalente en Python al inner join de SQL, how="left" indica que es left join y on indica la columna por la que se relacionan



Se realiza el agrupamiento en cubetas (databinning)



```
bins = [0,10000,20000,40000]
cars_bin=['Budget', 'Medium', 'Highend']
df['CarsRange'] = pd.cut(df['mean'], bins, right=False, labels=cars_bin)
df.head()
```

12. Elimine las columnas `car_ID`, `engineLocation` y `symboling` ya que una sola es un identificador, la ubicación del motor no es importante y la otra no aporta información valiosa al modelo.
13. Realice los histogramas de las columnas categóricas vs Precio junto con los gráficos de dispersión (`scatterplot`) de las columnas numéricas vs Precio.
14. Realice el diagrama de bigotes del precio respecto las siguientes características:

```
k = 0
plt.figure(figsize=(15, 36))
columns=["CompanyName", "fueltype", "carbody", "enginetype", "CarsRange"]
for col in columns:
 plt.subplot(8, 3, k + 1)
 sns.boxplot(x=col, y="price", data=df)
 plt.xticks(rotation=90)
 plt.title(f"Car Price by {col}", pad=10, fontweight="black", fontsize=12)
 k += 1
plt.tight_layout()
```

15. Elimine las columnas con alta cardinalidad excepto `enginetype` pues esta característica tiene un alto impacto en nuestra variable objetivo.
16. Elimine las columnas de varianza baja (ninguna, pero ejecute la prueba).
17. Elimine las características que tienen una correlación mayor a **0.85**
18. Convierta las columnas object a numéricas con el siguiente código:

```
cat_columns = HP.select_dtypes(['object']).columns
print(cat_columns)
for c in cat_columns:
 HP[c] = HP[c].astype('category')
HP[cat_columns] = HP[cat_columns].apply(lambda x: x.cat.codes)
```

19. La columna `CarsRange` para poder ser procesada por el modelo debería ser codificada con *one-hot*, pero la convertiremos a número y le indicaremos al modelo que es categórica (**C**)

```
gama=['Budget', 'Medium', 'Highend']
i=0
while i<3:
 df['CarsRange'].replace(gama[i], i, inplace=True)
 i=i+1
df['CarsRange'] = df['CarsRange'].astype('int')
```



20. Aplique las pruebas del factor de inflación de la varianza (VIF) para eliminar en cada iteración la característica con el mayor coeficiente VIF hasta que todas queden con

un valor inferior a 5. Debe ignorar todas las columnas categóricas y también las columnas 'horsepower' y 'carwidth' pues son de gran importancia para el modelo.

```
ignorecolumns=['price', 'fueltype', 'aspiration', 'carbody', 'drivewheel',
 'engine type', 'horsepower', 'carwidth']
X = df.drop(ignorecolumns,axis=1)
```

21. Muestre los primeros 10 renglones del dataframe actual y sus dimensiones.

22. Recuerde que parte del proceso de la Minería de Datos es envolverse del negocio, por lo que puede consultar los siguientes enlaces para conocer a que se refieren las características con las que trabajaremos:

- **Fueltype** tipo de combustible gasolina o diesel
- **Carbody** tipo de carrocería  
<https://www.motorpasion.com/espaciotoyota/sabes-que-tipo-carroceria-lleva-tu-coche-te-explicamos-facil-ejemplos>
  - **carbody hardtop**  
[https://es.wikipedia.org/wiki/Tipo\\_de\\_carrocería](https://es.wikipedia.org/wiki/Tipo_de_carrocería)
- **drive Wheel** rueda motriz  
<https://www.jeep.com.mx>
- **engine type** tipo de motor  
dohc (Dual OverHead Cam), dohcvc (Dual OverHead Cam and Valve), I (L engine), ohc (OverHead Cam), ohcf (OverHead Cam and Valve F engine), ohcv (OverHead Cam and Valve) and rotor (Rotary engine)
  - dohc  
<https://www.civictmotors.com/what-does-dohc-mean/>
  - ohc, dohcvc, ohcv  
<https://www.pruebaderuta.com/que-es-un-motor-sv-ohv-sohv-y-dohc.php>
  - Motor en línea L  
[https://www.motociclismo.es/consejos/motores-en-linea-son-comparativa-con-otros-ecn\\_271167\\_102.html](https://www.motociclismo.es/consejos/motores-en-linea-son-comparativa-con-otros-ecn_271167_102.html)
  - rotor  
<https://como-funciona.co/un-rotor/>
- **Horsepower** caballos de fuerza  
<https://www.kia.com>

23. Separe los datos en 80% entrenamiento y 20% pruebas (Xtrain, Xtest, Ytrain, Ytest)

24. Cree el modelo de regresión lineal múltiple utilizando el modo fórmula.



25. Mejore el modelo utilizando como variables categóricas las columnas: aspiration, carbody, drivewheel, enginetype y CarsRange
26. Elimine del modelo las características que son insignificantes por su  $p\text{-value} > 0.05$ .
27. Realice el diagnóstico de errores (residuos) de las predicciones del entrenamiento y realice los gráficos correspondientes.
28. Verifique la normalidad de los residuos con el test Shapiro-Wilk y con D'Agostino's K-squared
29. Calcule el rmse con los datos de prueba (Xtest)
30. Escriba la fórmula del modelo resultante. (markdown en el notebook)